



Universidade de Brasília – UnB  
Faculdade UnB Gama – FGA  
Engenharia de Software

**Desenvolvimento e Avaliação de Sistemas de  
Recomendação Centrados em Inteligência  
Artificial: Um Estudo de Caso sobre Satisfação  
do Usuário**

Autor: Cíbele Freitas Goudinho  
Orientador: Profa. Dra. Milene Serrano

Brasília, DF  
2024





Cibele Freitas Goudinho

# **Desenvolvimento e Avaliação de Sistemas de Recomendação Centrados em Inteligência Artificial: Um Estudo de Caso sobre Satisfação do Usuário**

Monografia submetida ao curso de graduação em Engenharia de Software da Universidade de Brasília, como requisito parcial para obtenção do Título de Bacharel em Engenharia de Software.

Universidade de Brasília – UnB

Faculdade UnB Gama – FGA

Orientador: Profa. Dra. Milene Serrano

Coorientador: Prof. Dr. Maurício Serrano

Brasília, DF

2024

---

Cibele Freitas Goudinho

Desenvolvimento e Avaliação de Sistemas de Recomendação Centrados em Inteligência Artificial: Um Estudo de Caso sobre Satisfação do Usuário/ Cibele Freitas Goudinho. – Brasília, DF, 2024-

36 p. : il. (algumas color.) ; 30 cm.

Orientador: Profa. Dra. Milene Serrano

Trabalho de Conclusão de Curso – Universidade de Brasília – UnB  
Faculdade UnB Gama – FGA , 2024.

1. sistemas de recomendação. 2. inteligência artificial. I. Profa. Dra. Milene Serrano. II. Universidade de Brasília. III. Faculdade UnB Gama. IV. Desenvolvimento e Avaliação de Sistemas de Recomendação Centrados em Inteligência Artificial: Um Estudo de Caso sobre Satisfação do Usuário

CDU 02:141:005.6

---

Cibele Freitas Goudinho

# **Desenvolvimento e Avaliação de Sistemas de Recomendação Centrados em Inteligência Artificial: Um Estudo de Caso sobre Satisfação do Usuário**

Monografia submetida ao curso de graduação  
em Engenharia de Software da Universidade  
de Brasília, como requisito parcial para ob-  
tenção do Título de Bacharel em Engenharia  
de Software.

Trabalho aprovado. Brasília, DF, de de 2024 – Data da aprovação do trabalho:

---

**Profa. Dra. Milene Serrano**  
Orientador

---

**Titulação e Nome do Professor**  
**Convidado 01**  
Convidado 1

---

**Titulação e Nome do Professor**  
**Convidado 02**  
Convidado 2

Brasília, DF  
2024



# Resumo

**Palavras-chave:** sistemas de recomendação. inteligência artificial.





# Abstract

This is the english abstract.

**Key-words:** recommender systems. artificial intelligence.



## Lista de ilustrações



## Lista de tabelas



# Lista de abreviaturas e siglas

IA	Inteligência Artificial
ML	<i>Machine Learning</i>
SR	Sistema de Recomendação





# Lista de símbolos

Γ      Letra grega Gama



# Sumário

<b>1</b>	<b>INTRODUÇÃO</b>	<b>19</b>
<b>1.1</b>	<b>Contextualização</b>	<b>19</b>
<b>1.2</b>	<b>Justificativa</b>	<b>21</b>
<b>1.3</b>	<b>Questões de Pesquisa e Desenvolvimento</b>	<b>22</b>
<b>1.4</b>	<b>Objetivos</b>	<b>23</b>
1.4.1	Objetivo Geral	23
1.4.2	Objetivos Específicos	23
<b>1.5</b>	<b>Organização da Monografia</b>	<b>24</b>
<b>2</b>	<b>REFERENCIAL TEÓRICO</b>	<b>25</b>
<b>3</b>	<b>SUPORTE TECNOLÓGICO</b>	<b>27</b>
<b>4</b>	<b>METODOLOGIA</b>	<b>29</b>
<b>5</b>	<b>PROPOSTA</b>	<b>31</b>
<b>6</b>	<b>CONCLUSÃO</b>	<b>33</b>
	<b>REFERÊNCIAS</b>	<b>35</b>



# 1 Introdução

Este capítulo introduz o contexto, no qual esta trabalho está inserido. Inicialmente, aborda-se a [Contextualização](#), que traz o foco de interesse desse trabalho (inteligência artificial e sistemas de recomendação). Na sequência, consta a [Justificativa](#) para a realização do mesmo, além da [Questões de Pesquisa e Desenvolvimento](#) a ser respondida, e os [Objetivos](#) que se pretendem ser alcançados. E por fim, é abordado a [Organização da Monografia](#).

## 1.1 Contextualização

Sistemas de recomendação (SR) são algoritmos de software projetados para analisar o comportamento passado do usuário e suas preferências, com o intuito de sugerir itens que possam ser de seu interesse ([CHEW; HAW; SUBRAMANIAM, 2020](#)). No contexto da sociedade atual, com grande conjunto de dados disponíveis, tem se tornado cada vez mais desafiador para os usuários encontrarem exatamente o que procuram em meio às vastas opções. Dessa forma, os sistemas de recomendação surgem como meios para facilitar a descoberta de conteúdo relevante em ambientes digitais. Grandes empresas utilizam sistemas de recomendação como estratégia para conquistar e auxiliar seus clientes, como o Youtube e a Netflix ([ZHANG et al., 2019](#)).

Os benefícios dos sistemas de recomendação na sociedade atual são significativos. Eles não apenas facilitam a descoberta de novos produtos e conteúdos, mas também aumentam o engajamento do usuário e impulsionam as vendas e a receita para empresas e plataformas digitais. Além disso, ao personalizar a experiência do usuário, os sistemas de recomendação podem melhorar a satisfação do cliente e a fidelidade à marca ([GUNAWARDANA; SHANI; YOGEV, 2022](#)).

No entanto, os sistemas de recomendação possuem desafios. De acordo com a pesquisa Khusro; Ali; Ullah (2016) os principais problemas que ocorrem no contexto dos sistemas de recomendação são:

- *Cold Start*: ocorre quando há nenhum ou poucos dados para iniciar as sugestões, acontecendo principalmente com novos usuários. Esse desafio também é conhecido como "partida a frio";
- Esparsidade dos dados: ocorre quando a matriz de dados dos usuários possui muitos espaços vazios. Isso ocorre, principalmente, devido à grande quantidade de itens, o

que dificulta o preenchimento pleno desses itens; ou ainda pela falta de avaliações dos usuários para cada item;

- Escalabilidade: ocorre por haver a necessidade de uma grande rede de usuários, gerando outros problemas, por exemplo, baixo desempenho;
- Diversidade: ocorre pela dificuldade em conciliar itens diferentes (diferenciação) e itens similares (sobreposição). A diferenciação permite aos usuários receberem itens mais variados, algo que pode ser do seu interesse. Já a sobreposição confere itens apenas itens similares, não recomendando itens que possuem ligações mais distantes, e
- Efeito de habituação: ocorre quando o grande número de informações gera um efeito de costume no usuário, ou seja, certa rotina em suas preferências. Isso pode fazer com que várias recomendações sejam ignoradas, recomendando-se sempre a mesma coisa.

Outra tecnologia que vem avançando hoje é a Inteligência Artificial (IA), que tem permeado diversos setores da nossa sociedade ([LAKEHOUSE, 2023](#)). IA refere-se à capacidade de sistemas computacionais executarem tarefas que normalmente exigiriam inteligência humana, tais como: aprendizado, raciocínio, reconhecimento de padrões e tomada de decisões. Uma área específica da IA que tem ganhado destaque é o *Deep Learning* (DL), um ramo do aprendizado de máquina que se baseia em redes neurais artificiais para realizar tarefas complexas de forma automatizada. Essas tecnologias trazem vários benefícios, desde a automação de processos até a análise de grandes volumes de dados, otimizando operações e impulsionando a tomada de decisões em diversos setores (saúde, transporte, entretenimento, dentre outros) ([SULEIMENOV et al., 2020](#)).

No intuito de mitigar os desafios inerentes aos sistemas de recomendação, pode-se fazer uso de *Deep Learning*.

Usar Deep Learning pode ajudar a mitigar o desafio Cold Start, ou "partida a frio". Isso ocorre, pois Deep Learning permite aprender representações complexas a partir de dados brutos. Ao utilizar técnicas como redes neurais, os sistemas de recomendação podem extrair padrões e relações significativas dos dados, mesmo quando há poucos dados disponíveis para novos usuários. Isso permite que o sistema forneça recomendações mais precisas e relevantes, mesmo para usuários com histórico limitado ([ANALYTICS, 2021](#)).

No desafio de esparsidade dos dados, Deep Learning permite aprender com base em representações densas de informações, mesmo que a matriz que comporta tais informações não seja plena, com todos os itens preenchidos, restando espaços em branco ([HEIDARI; MORADI; KOOCHARI, 2022](#)). Nesse cenário, técnicas como autoencoders podem ser usadas para preencher lacunas nos dados, gerando representações completas e

semanticamente coerentes. Explicações complementares de como funcionam tais técnicas serão conferidas no Capítulo 2 - Referencial Teórico.

Por serem altamente paralelizáveis, técnicas de Deep Learning podem ser implementadas em sistemas distribuídos. Essa estratégia permite lidar com grande quantidade de dados e usuários. Ao usar técnicas de treinamento distribuído e otimização eficiente, os sistemas de recomendação baseados em Deep Learning podem escalar para grandes conjuntos de dados e redes de usuários sem comprometer o desempenho (YAN et al., 2015).

Deep Learning ajuda a melhorar a diversidade das recomendações ao aprender representações mais abrangentes dos itens e usuários. Além disso, permite que o sistema de recomendação perceba similaridades com base nos itens e usuários. Como resultado, tende-se a recomendações mais equilibradas e assertivas. Nos estudos realizados até o momento pela autora, cabe menção à técnica de introdução de fatores de diversidade no processo de geração de recomendações, conforme abordado em (KINGMA et al., 2016). Essa técnica busca garantir que os usuários recebam uma variedade de itens relevantes. Constam outros detalhes sobre o funcionamento dessa técnica no Capítulo 2 - Referencial Teórico.

Sistemas de recomendação orientados a Deep Learning são capazes de aprender continuamente, centrados nos *feedbacks* dos usuários. Adicionalmente, são sistemas capazes de adaptar as recomendações ao longo do tempo. Essas particularidades de aprendizado contínuo e adaptabilidade possibilitam que as recomendações permaneçam atualizadas e relevantes aos interesses dos usuários, mesmo após longos períodos de uso (LOMONACO, 2019). Portanto, isso mitiga o efeito de habituação comentado anteriormente nesse capítulo.

Diante do exposto, usar recursos da IA em sistemas de recomendação representa uma oportunidade para melhorar as recomendações conferidas aos usuários. Ao combinar algoritmos avançados de IA com dados detalhados sobre o comportamento do usuário, é possível gerar recomendações mais precisas e relevantes, que atendam às necessidades e preferências individuais do usuário de forma mais eficaz (KARATZOGLOU; HIDASI, 2017). Essa abordagem híbrida permite que os sistemas de recomendação aprendam e se adaptem continuamente, melhorando sua capacidade de prever e antecipar as preferências do usuário ao longo do tempo.

## 1.2 Justificativa

Nos últimos anos, tem sido observado um aumento na relevância da Web como meio para transações eletrônicas e comerciais, que é um fator importante no desenvolvimento de sistemas de recomendação centrados em Inteligência Artificial (IA) (AGGARWAL, 2016).

Isso se dá principalmente pelas vantagens que esse tipo de sistema confere às companhias, tais como: aumento do número de vendas; maior diversidade de itens vendidos; aumento da satisfação dos usuários, maior fidelidade desses usuários, e melhor atendimento quanto às necessidades dos usuários (GUNAWARDANA; SHANI; YOGEV, 2022). Dentre as companhias de comércio eletrônico que já fazem uso de sistemas de recomendação centrados na IA, destacam-se: Amazon, Netflix, IMDb e Youtube. As mesmas utilizam sistemas de recomendação para oferecer sugestões personalizadas aos seus usuários (KONSTAN; RIEDL, 2012).

Apesar dos benefícios proporcionados pelos sistemas de recomendação, também é importante reconhecer suas limitações e desafios. Estudos têm demonstrado que muitos usuários não fornecem *feedbacks* ou avaliações aos sistemas de recomendação, o que resulta em um problema conhecido como "partida a frio" (*cold start*), ou ainda dificultam na escalabilidade, à medida que a rede de usuários cresce ou a base de dados necessita de atualização (MISHRA et al., 2021).

Em meio a esse cenário, torna-se relevante considerar o impacto da crescente utilização da IA no desenvolvimento e na evolução de sistemas de recomendação. Estudos indicam que o número de empresas que utilizam serviços baseados em IA cresceu significativamente nos últimos anos, o que evidencia a importância e o potencial dessas tecnologias (LAKEHOUSE, 2023). É nesse contexto que se destaca a relevância da aplicação de técnicas avançadas de IA, como redes neurais, para aprimorar a capacidade dos sistemas de recomendação em entender e antecipar as preferências dos usuários (ZHANG et al., 2019).

Considerando os benefícios apontados anteriormente no que compreende o uso de IA em sistemas de recomendação, o presente trabalho visa a realização de um estudo, procurando investigar estratégias e técnicas avançadas de IA para o desenvolvimento de sistemas de recomendação mais eficientes e precisos. Sistemas esses capazes de proporcionar uma experiência personalizada e satisfatória aos usuários em diferentes contextos e aplicações.

### 1.3 Questões de Pesquisa e Desenvolvimento

Ao final desse trabalho, pretende-se responder às seguintes questões:

Questão de Desenvolvimento: Como um sistema de recomendação centrado em Inteligência Artificial pode ser desenvolvido?

Questão de Pesquisa: Esse sistema de recomendação centrado em IA, de fato, proporciona maior satisfação aos seus usuários?

Com a exposição das questões, cabem dois esclarecimentos adicionais.



O primeiro compreende deixar claro sobre o escopo do sistema de recomendação pretendido. Pretende-se que seja um sistema de recomendação que faz uso de algumas técnicas de IA, sendo essas as mais recomendadas pela literatura em estudo. Tais técnicas serão escolhidas com base nos desafios acordados anteriormente, orientando-se pelos autores Khusro; Ali; Ullah (2016). Será um sistema de escopo menor, mas que será documentado para permitir que outros interessados consigam usá-lo de base.

Segundo Monique Esperidião (2005), satisfação de usuário é um critério qualitativo. Portanto, trata-se de um requisito não funcional, subjetivo. No intuito de conferir maior clareza sobre como "mensurar" a satisfação do usuário, pretende-se fazer uso de questionários, junto ao público alvo de cada domínio de interesse utilizado ao longo desse trabalho, para coletar *feedbacks* sobre as impressões desses usuários quanto às recomendações recebidas, sem e com o auxílio de um sistema de recomendação centrado em IA. A decisão de usar um questionário baseou-se na literatura. Segundo a autora Monique Esperidião (2005), dentre os métodos quantitativos, destacam-se *surveys*, incluindo o uso de questionários fechados. Nesses questionários, as questões estão associadas a uma escala de valores que procuram mensurar a satisfação dos usuários. Na verdade, costumam mensurar aspectos associados à satisfação, no caso: expectativas e percepções. Ainda de acordo com Monique Esperidião (2005), há possibilidade de usar métodos qualitativos, mas deve-se ter em mente que os mesmos costumam ser criticados pelos especialistas, por incorrerem em pesquisas com vies, dentre outros problemas. O presente trabalho fará uso de uma abordagem híbrida, quantitativa e qualitativa, conforme alguns autores defendem (MINAYO; SANCHES, 1993). Nesse contexto, cabe colocar que, nessa abordagem híbrida, a parte quantitativa e a parte qualitativa não se encontram em oposição, mas sim de continuidade e complementaridade. O questionário se orientará por uma escala em números, ou seja, quantitativa, mas que seguirá uma análise interpretativa sobre esses números, sendo assim conferindo, adicionalmente, um viés qualitativo. Colocações complementares sobre o método de análise de resultados ocorrerão no Capítulo 4 - Metodologia.

## 1.4 Objetivos

Os objetivos do trabalho foram organizados em Objetivo Geral, que confere uma visão mais abrangente do que se pretende atingir com a realização do trabalho, e Objetivos Específicos, compreendendo metas de menor escopo a serem cumpridas para que seja viável atingir o objetivo geral.

### 1.4.1 Objetivo Geral

Esse trabalho tem como objetivo geral um estudo sobre sistemas de recomendação centrados em Inteligência Artificial, revelando como desenvolvê-los e analisando se os

mesmos melhoram a satisfação dos usuários.

### 1.4.2 Objetivos Específicos

Na perspectiva de alcançar o objetivo geral, foram definidos objetivos específicos, conforme apresentado a seguir:

1. Levantamento sobre sistemas de recomendação;
2. Levantamento, no contexto da IA, de algoritmos de Deep Learning que mais atendam à proposta desse trabalho;
3. Identificação de quais informações serão necessárias para especificar uma base de dados para o projeto;
4. Treinamento da base de dados orientando-se pelos algoritmos de Deep Learning levantados;
5. Desenvolvimento de um sistema de recomendação centrado em IA, mais especificamente usando algoritmos de Deep Learning, e
6. Análise da satisfação do usuário sem e com o uso do sistema de recomendação desenvolvido.

## 1.5 Organização da Monografia

Esta monografia está organizada em capítulos, conforme consta a seguir:

**Capítulo 2 - Referencial Teórico:** aborda fundamentos, conceitos, princípios e práticas relevantes para o tema, em específico, sistemas de recomendação centrados em Inteligência Artificial;

**Capítulo 3 - Suporte Tecnológico:** apresenta as principais tecnologias utilizadas para o desenvolvimento do trabalho;

**Capítulo 4 - Metodologia:** esclarece sobre os métodos que guiam a elaboração do trabalho, apresentando desde a classificação da pesquisa, e detalhando os métodos investigativo, de desenvolvimento e de análise de resultados;

**Capítulo 5 - Proposta:** confere uma visão mais detalhada da proposta, procurando retomar o contexto, e apresentando outras nuances sobre os algoritmos de Deep Learning escolhidos e a preparação da base de dados, e

**Capítulo 6 - Conclusão:** evidencia o status atual do trabalho, retomando objetivos já alcançados nessa primeira etapa, em andamento, e que ainda serão cumpridos

com a realização da segunda etapa. Além disso, procura-se destacar sobre as principais contribuições do trabalho e as percepções da autora ao se concluir a primeira etapa.



## 2 Referencial Teórico



### 3 Suporte Tecnológico





## 4 Metodologia



## 5 Proposta



## 6 Conclusão



# Referências

AGGARWAL, C. C. An introduction to recommender systems. In: \_\_\_\_\_. *Recommender Systems: The Textbook*. Cham: Springer International Publishing, 2016. p. 1–28. ISBN 978-3-319-29659-3. Disponível em: <[https://doi.org/10.1007/978-3-319-29659-3\\_1](https://doi.org/10.1007/978-3-319-29659-3_1)>. Citado na página 21.

ANALYTICS, E. *Cold Start Problem*. 2021. Disponível em: <<https://www.expressanalytics.com/blog/cold-start-problem/>>. Citado na página 20.

CHEW, L.-J.; HAW, S.-C.; SUBRAMANIAM, S. Recommender system for retail domain: An insight on techniques and evaluations. In: *Proceedings of the 12th International Conference on Computer Modeling and Simulation*. New York, NY, USA: Association for Computing Machinery, 2020. (ICCMS '20), p. 9–13. ISBN 9781450377034. Disponível em: <<https://doi.org/10.1145/3408066.3408101>>. Citado na página 19.

GUNAWARDANA, A.; SHANI, G.; YOGEV, S. Evaluating recommender systems. In: \_\_\_\_\_. *Recommender Systems Handbook*. New York, NY: Springer US, 2022. p. 547–601. ISBN 978-1-0716-2197-4. Disponível em: <[https://doi.org/10.1007/978-1-0716-2197-4\\_15](https://doi.org/10.1007/978-1-0716-2197-4_15)>. Citado 2 vezes nas páginas 19 e 21.

HEIDARI, N.; MORADI, P.; KOOCHARI, A. An attention-based deep learning method for solving the cold-start and sparsity issues of recommender systems. *Knowledge-Based Systems*, v. 256, p. 109835, 2022. ISSN 0950-7051. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0950705122009339>>. Citado na página 20.

KARATZOGLOU, A.; HIDASI, B. Deep learning for recommender systems. In: *Proceedings of the Eleventh ACM Conference on Recommender Systems*. New York, NY, USA: Association for Computing Machinery, 2017. (RecSys '17), p. 396–397. ISBN 9781450346528. Disponível em: <<https://doi.org/10.1145/3109859.3109933>>. Citado na página 21.

KINGMA, D. P. et al. Improving variational inference with inverse autoregressive flow. In: *Advances in Neural Information Processing Systems*. [S.l.: s.n.], 2016. p. 4743–4751. Citado na página 21.

KONSTAN, J. A.; RIEDL, J. *DECONSTRUCTING RECOMMENDER SYSTEMS*. 2012. Disponível em: <<https://spectrum.ieee.org/deconstructing-recommender-systems>>. Citado na página 22.

LAKEHOUSE, D. *Perspectiva de dados + IA 2023*. 2023. Disponível em: <[https://www.databricks.com/br/resources/ebook/state-of-data-ai?scid=7018Y000001Fi0cQAC&utm\\_medium=paid+search&utm\\_source=google&utm\\_campaign=20613856686&utm\\_adgroup=152642604685&utm\\_content=ebook&utm\\_offer=state-of-data-ai&utm\\_ad=676095019567&utm\\_term=ia%20databricks&gad\\_source=1&gclid=CjwKCAiAi6uvBhADEiwAWiyRdhu4vCcRtEYsvjz\\_adMw9KeOINlakog84AuYZQL8vwEI0NozB1M97hoC2boQAvD\\_BwE](https://www.databricks.com/br/resources/ebook/state-of-data-ai?scid=7018Y000001Fi0cQAC&utm_medium=paid+search&utm_source=google&utm_campaign=20613856686&utm_adgroup=152642604685&utm_content=ebook&utm_offer=state-of-data-ai&utm_ad=676095019567&utm_term=ia%20databricks&gad_source=1&gclid=CjwKCAiAi6uvBhADEiwAWiyRdhu4vCcRtEYsvjz_adMw9KeOINlakog84AuYZQL8vwEI0NozB1M97hoC2boQAvD_BwE)>. Citado 2 vezes nas páginas 20 e 22.

LOMONACO, V. Continual learning with deep architectures. alma, 2019. Citado na página 21.

MINAYO, M. C. d. S.; SANCHES, O. Quantitativo - qualitativo: Oposição ou complementaridade? *Cadernos de Saúde Pública*, v. 9, n. 3, p. 239–262, 1993. Citado na página 23.

MISHRA, N. et al. Research problems in recommender systems. *Journal of Physics: Conference Series*, IOP Publishing, v. 1717, n. 1, p. 012002, jan 2021. Disponível em: <<https://dx.doi.org/10.1088/1742-6596/1717/1/012002>>. Citado na página 22.

SULEIMENOV, I. E. et al. Artificial intelligence: what is it? In: *Proceedings of the 2020 6th International Conference on Computer and Technology Applications*. New York, NY, USA: Association for Computing Machinery, 2020. (ICCTA '20), p. 22–25. ISBN 9781450377492. Disponível em: <<https://doi.org/10.1145/3397125.3397141>>. Citado na página 20.

YAN, F. et al. Performance modeling and scalability optimization of distributed deep learning systems. In: *Proceedings of the 21th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York, NY, USA: Association for Computing Machinery, 2015. (KDD '15), p. 1355–1364. ISBN 9781450336642. Disponível em: <<https://doi.org/10.1145/2783258.2783270>>. Citado na página 21.

ZHANG, S. et al. Deep learning based recommender system: A survey and new perspectives. *ACM Comput. Surv.*, Association for Computing Machinery, New York, NY, USA, v. 52, n. 1, feb 2019. ISSN 0360-0300. Disponível em: <<https://doi.org/10.1145/3285029>>. Citado 2 vezes nas páginas 19 e 22.